

# Regresión Logística

The background of the slide is a photograph of a clear night sky. The Milky Way galaxy is visible as a bright, hazy band of light stretching across the upper half of the image. Numerous individual stars are scattered throughout the dark blue and black sky. In the lower portion of the image, the dark, silhouetted branches of evergreen trees are visible, framing the bottom and right sides of the scene.

# Clasificación Binaria

mean radius	target
17,99	1
20,57	1
16,13	1
19,81	1
13,54	0
13,08	0
15,34	1
21,16	1
17,57	1
11,84	1
17,02	1
12,05	0
13,49	0
11,76	0
13,64	0
11,94	0
18,22	1

**Objetivo:**

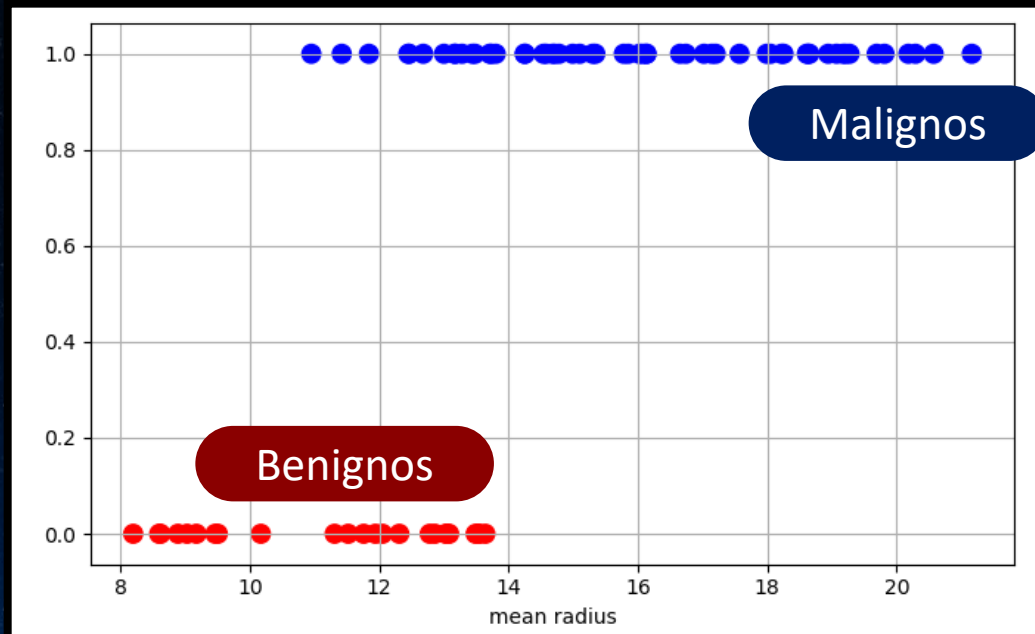
## **Clasificación Binaria**

Clasificar tumores Benignos (0) y Malignos (1) en base a su tamaño.




# Clasificación Binaria

mean radius	target
17,99	1
20,57	1
16,13	1
19,81	1
13,54	0
13,08	0
15,34	1
21,16	1
17,57	1
11,84	1
17,02	1
12,05	0
13,49	0
11,76	0
13,64	0
11,94	0
18,22	1



# Clasificación Binaria

¿Cómo podemos separar las clases?



Ej: Clasificador ad hoc


$$f(x) = \begin{cases} 1 & \text{si } x > 13 \\ 0 & \text{si } x \leq 13 \end{cases}$$

**Problemas:**

- No es derivable
- Muy restrictivo

# Clasificación Binaria

¿Cómo podemos separar las clases?




**Regresión lineal:**

- Valores fuera de rango
- Solución: acotar

# Clasificación Binaria

¿Cómo podemos separar las clases?



**Regresión lineal acotada:**


$$g(x) = \begin{cases} 1 & \text{si } x \geq 17 \\ f(x) & \text{si } 17 > x > 9 \\ 0 & \text{si } x \leq 9 \end{cases}$$

- Difícil de optimizar




# Clasificación Binaria


**Regresión Logística = Regresión Lineal + Función Logística**



+



=



# Función Logística o Sigmoidea

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\sigma(f(x)) = \frac{1}{1 + e^{-wx-b}}$$


- Tiene un rango de salida entre 0 y 1.
- La función de Error es diferenciable.

$$\text{Derivada} = \sigma(z) * (1 - \sigma(z))$$

- $\sigma(z)$  tiene dos asíntotas horizontales:

Tiende a 1 cuando  $x$  tiende a  $+\infty$

Tiende a 0 cuando  $x$  tiende a  $-\infty$






# Sigmoidea como Probabilidades

Otra ventaja es que puedo interpretar la función la “probabilidad de que  $y=1$ ”.

En el ejemplo de los tumores. Si para un ejemplo particular (supongamos  $x=14$ ), la hipótesis me retorna 0.7, significa que hay un 70% de probabilidad de que sea un tumor maligno.

Formalmente:  $\sigma(x) = P(y=1 \mid x; w)$


Por otro lado,  $P(y=0 \mid x; w) = 1 - P(y=1 \mid x; w)$



# Sigmoidea como Probabilidades

Finalmente, ponemos un umbral para clasificar

$$y = \begin{cases} 1 & \text{si } \sigma(x) > 0,5 \\ 0 & \text{si } \sigma(x) \leq 0,5 \end{cases} \quad \begin{aligned} &\rightarrow wx + b > 0 \\ &\rightarrow wx + b \leq 0 \end{aligned}$$



mean radius	$\sigma(x)$	$Y'(x)$
17,99	0,71	1
20,57	0,88	1
19,69	0,76	1
13,54	0,42	0
9,52	0,25	0

☐  $m = 5.9$   
 -10  10


☐  $b = -0.8$   
 -50  20

☒  $f(x) = \frac{1}{1 + e^{-(mx+b)}}$   
 $\rightarrow \frac{1}{1 + e^{-(5.9x-0.8)}}$

☐  $h(x) = mx + b$   
 $\rightarrow 5.9x - 0.8$

☐  $A = \text{Punto}(\text{EjeX})$   
 $\rightarrow (0.4, 0)$

☐  $B = \text{Punto}(\text{EjeX})$   
 $\rightarrow (0.78, 0)$





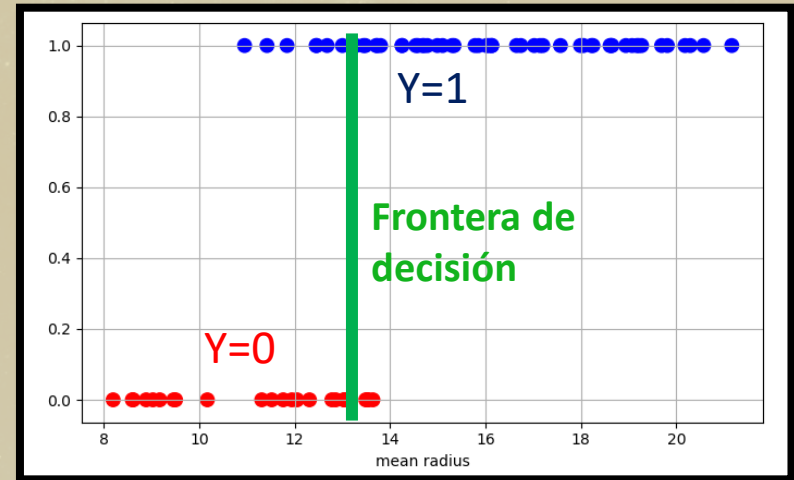
# Frontera de decisión 1D

Supongamos, para nuestro problema de tumores, que

$w = 0,3$  y  $b = -4$ , umbral  $= 0.5$

Entonces,  $y = 1$  si  $f(x) > 0$   
si  $0,3x - 4 > 0$   
 $x > \frac{4}{0,3}$   
 $y = 1$  si  $x > 13,33$


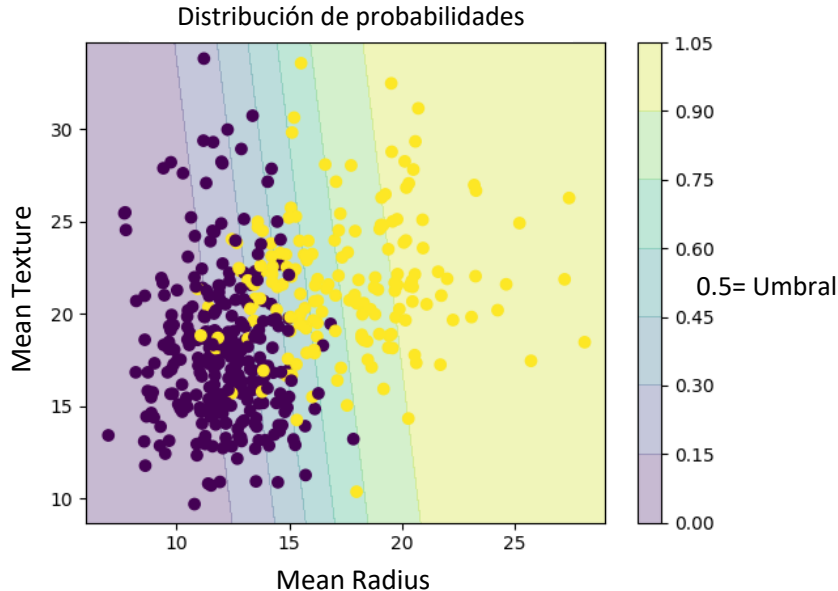
Frontera de Decisión  $x = 13,33$



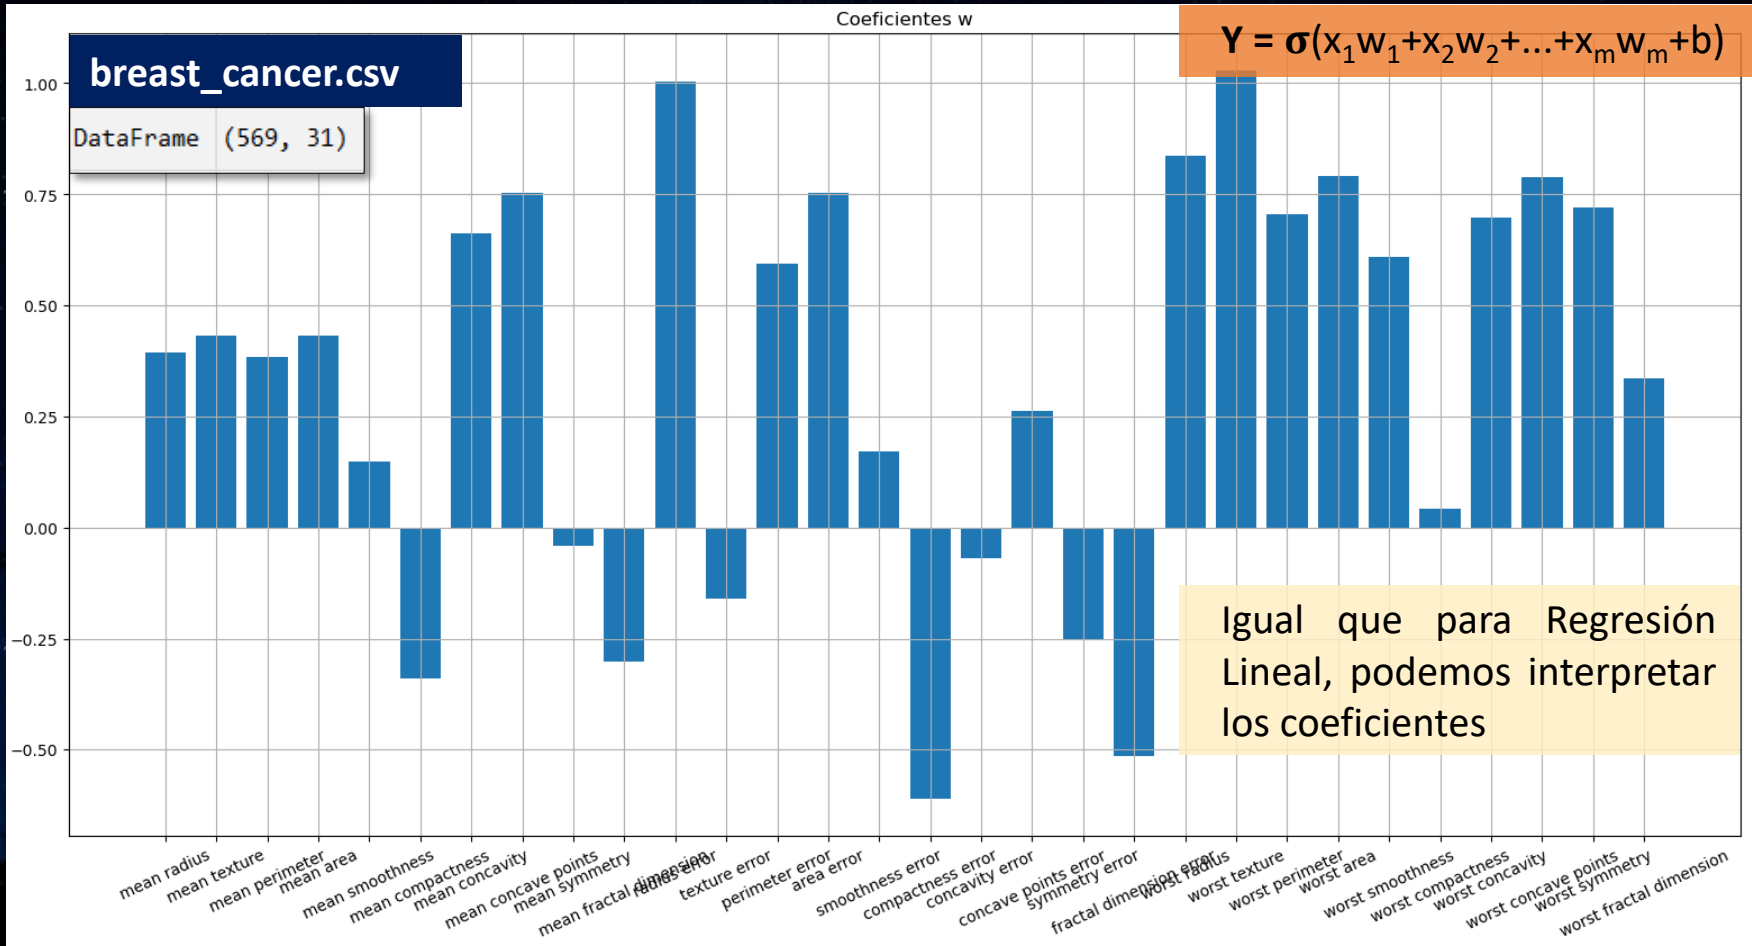
# Frontera de decisión 2D

- 2 variables para cada registro
- $\sigma(x_1, x_2) = \sigma(w_1x_1 + w_2x_2 + b)$
- $w = [0.47, 0.05]$ ,  $b = -8$

$$y = 1 \quad \text{si} \quad \sigma(x) > 0,5 \quad \rightarrow \quad w_1x_1 + w_2x_2 + b > 0$$
$$0,47x_1 + 0,05x_2 - 8 > 0$$
$$0,47x_1 + 0,05x_2 > 8$$
$$x_2 = 160 - 9,4x_1$$



# Modelo ND







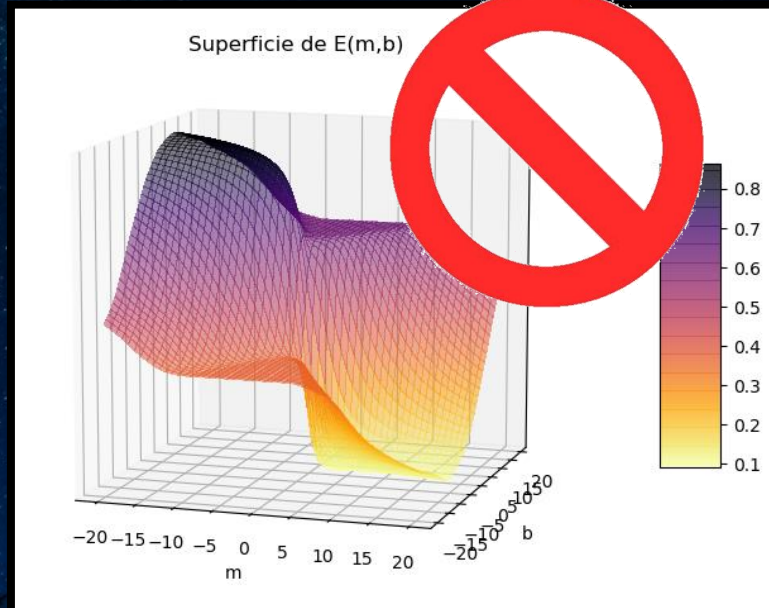
# Entropía cruzada

(Error para Regresión Logística)

# Error Cuadrático Medio

- $E = 1/n \sum_i^n E_i$
- $E_i = (\sigma(mx_i+b) - y_i)^2$
- Funciona, pero
  - ECM de  $\sigma(mx+b)$  no es apropiado
  - $E$  no es convexa
- **Entropía Cruzada**
  - Convexa para  $\sigma(mx_i+b)$
  - Mide distancia entre distribuciones de probabilidades.

## ECM de $\sigma(mx+b)$



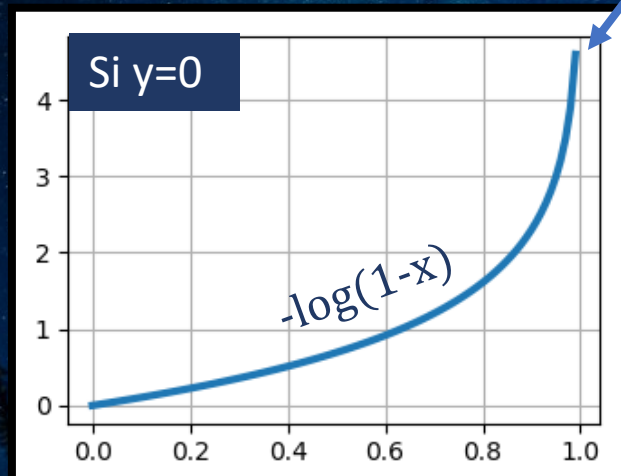



# Entropía Cruzada

$$E = \frac{1}{n} \sum_i^n E_i$$

$$E_i = \begin{cases} -\log(\sigma(x_i)) & \text{si } y = 1 \\ -\log(1 - \sigma(x_i)) & \text{si } y = 0 \end{cases}$$

Si  $y = 0$  & mi modelo dijo 1, entonces el error es muy alto





# Entropía Cruzada

$$E = \frac{1}{n} \sum_i^n E_i$$

$$E_i = \begin{cases} -\log(\sigma(x_i)) & \text{si } y = 1 \\ -\log(1 - \sigma(x_i)) & \text{si } y = 0 \end{cases}$$

Podemos escribir la función partida en una sola línea:

$$E_i = -y \log(\sigma(x_i)) - ((1 - y) \log(1 - \sigma(x_i)))$$

Los coeficientes “ $y$ ”, “ $(1 - y)$ ”, actúan como “if-else”

Para cada  $x_i$  solo se computa el  **$-\log$**  de la probabilidad de pertenencia a su clase.

# Entropía Cruzada

## Entr. Cruzada como Distancia entre distribuciones

- $f(x) = 0.3$ 
  - $P(x \text{ es de clase} = 1) = 0.3$
  - $P(x \text{ es de clase} = 0) = 1 - P(x \text{ es de clase} = 1) = 1 - 0.3 = 0.7$
  - $P(x \text{ es de clase} = 1)$  y  $P(x \text{ es de clase} = 0)$  forman una distribución de probabilidad
- **ECM**
  - Mide distancia entre puntos. Distancia euclídea al cuadrado
- **Entropía Cruzada**
  - Mide distancia entre distribuciones de probabilidad
  - Distancia Kullback-Leibler

# Derivadas Entropía Cruzada

- $\frac{\delta E}{\delta b} = \frac{1}{n} \sum_i^n y_i - f(x_i)$
- $\frac{\delta E}{\delta m} = \frac{1}{n} \sum_i^n (y_i - f(x_i)) x_i$
- Son iguales que las de Regresión Lineal (  $f(x)=\sigma(mx+b)$  )
- *Mismas ecuaciones de Descenso de Gradiente*  
$$b = b - \alpha \delta E(m,b)/\delta b$$
$$m = m - \alpha \delta E(m,b)/\delta m$$



# Métrica Accuracy

- Valores de entropía cruzada: **0 a  $+\infty$**

Difíciles de interpretar

Y	Y'	Acierto
1	1	1
1	0	0
0	0	1
0	1	0
0	1	0

**Accuracy** = % de ejemplos que clasificó correctamente.

Métrica para Clasificación.

Ejemplo: 2 / 5 -> **Acc = 0,4** (o 40%)

# Resumen

## Regresión Logística

- Permite modelar probabilidades
- Modelo  $Y = f(x_1, x_2, \dots, x_m) = \sigma(x_1 w_1 + x_2 w_2 + \dots + x_m w_m + b)$  ,  
$$\sigma(x) = 1/(1+e^{-x})$$

Interpretación de la salida del modelo como una probabilidad.

- Umbral -> Convierte probabilidades en clases.  
-> Frontera de decisión.
- Entropía cruzada -> Métrica de error. Mide distancia entre distrib. probabilidades.

